.UBAfiuba
FACULTAD DE INGENIERÍA

Laboratorio de Sistemas Embebidos



Arquitectura de Datos

Especialización en Internet de las Cosas

Docente:

Lacheski, Martín Anibal

Clase 8:

Arquitecturas de Datos y Grandes Volúmenes

Todas las imágenes utilizadas son libres o de creación propia

Arquitectura de Datos

Hasta ahora aprendimos a almacenar, administrar y escalar una base

En las clases anteriores aprendimos a:

- modelar información;
- implementar y consultar bases relacionales;
- optimizar estructuras y consultas;
- utilizar modelos NoSQL;
- combinar mecanismos de persistencia;
- administrar usuarios, permisos y aislamiento;
- recuperar información ante fallos;
- utilizar replicación, particionamiento y escalabilidad.

Ahora aparece una nueva pregunta:

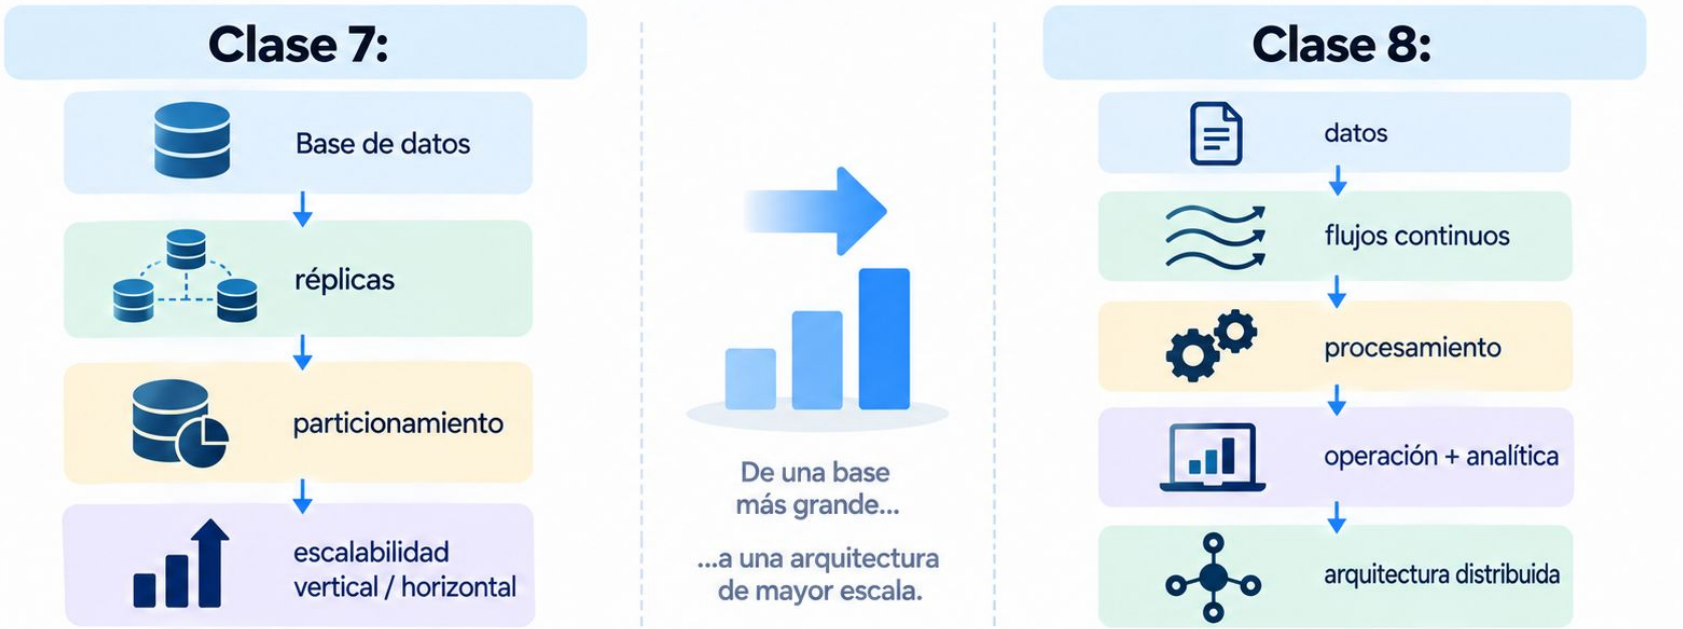
¿qué ocurre cuando el volumen y la velocidad de los datos empiezan a superar lo que resulta cómodo resolver con una única base operativa?



Escalar una base de datos es una parte del problema.
Cuando el sistema crece mucho, también aparece la necesidad de separar o distribuir almacenamiento y procesamiento.

Cambio de escala

Hoy empezamos a pensar arquitecturas de mayor escala



La pregunta ya no es solamente cómo crece una base,
sino cómo evoluciona toda la arquitectura de datos.

Objetivos de la clase

Reconocer cuándo una arquitectura convencional comienza a encontrar límites

Vamos a aprender a:

- reconocer qué significa trabajar con grandes volúmenes;
- comprender por qué aparecen arquitecturas distribuidas;
- distinguir operación transaccional y análisis;
- diferenciar batch, microbatch y streaming;
- introducir Data Warehouse, Data Lake y Data Lakehouse;
- pensar cómo evolucionaría el caso guía;
- dejar planteadas las bases conceptuales para materias posteriores.



El objetivo no es profundizar herramientas de Big Data, sino comprender cuándo y por qué una arquitectura necesita evolucionar.

El caso vuelve a crecer

Ahora la escala empieza a cambiar el problema

El sistema de monitoreo posee ahora:

- decenas de miles de dispositivos;
- mediciones generadas continuamente;
- cientos de millones de registros históricos;
- múltiples organizaciones y ubicaciones;
- varios años de información acumulada;
- aplicaciones que necesitan responder rápidamente;
- procesos analíticos sobre grandes períodos;
- eventos que pueden requerir reacción en pocos segundos.

La arquitectura que construimos hasta ahora sigue siendo válida.

Pero aparecen nuevas preguntas:

- ¿todo debería procesarse en la misma base?;
- ¿cómo analizamos grandes históricos sin afectar la operación?;
- ¿qué ocurre cuando necesitamos procesar datos continuamente?;
- ¿cuándo tiene sentido distribuir almacenamiento o procesamiento?

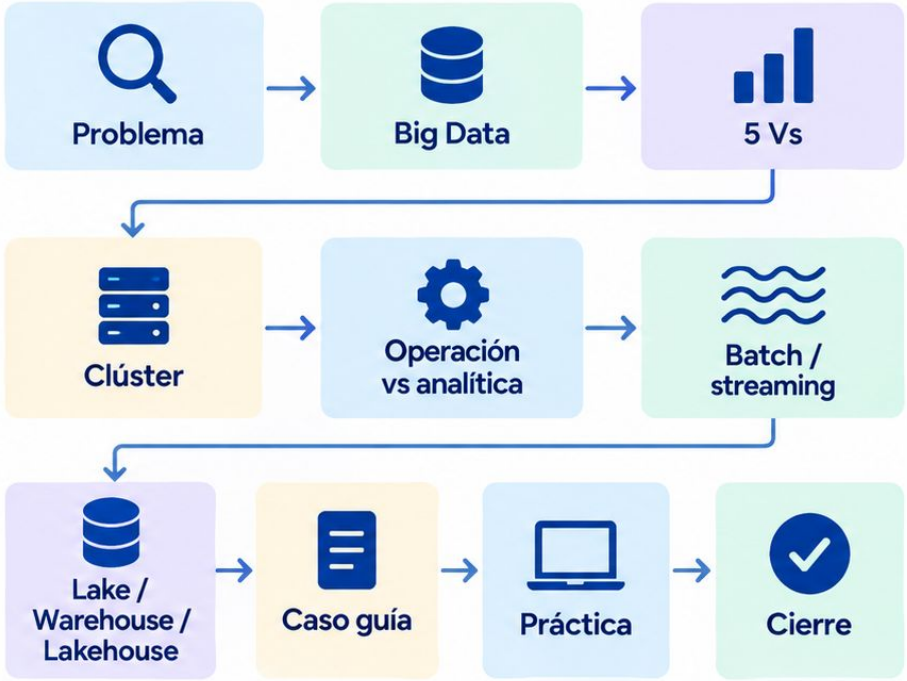


El problema ya no es solamente almacenar más datos.
También necesitamos decidir cómo procesarlos y cómo separar diferentes tipos de carga.

Arquitectura de Datos

Agenda del día

- ¿Cuándo empieza el problema?
- Big Data como cambio de escala.
- Grandes volúmenes y 5 Vs.
- Nodos, clúster, partición y réplica.
- Operación transaccional y analítica.
- Batch, microbatch y streaming.
- Data Warehouse, Data Lake y Lakehouse.
- Evolución del caso guía.
- Demostración / desarrollo práctico.
- Cierre.



Vamos a recorrer el problema desde el crecimiento de los datos hasta las primeras decisiones de arquitectura de mayor escala.

1

¿Cuándo empieza el problema?



El caso vuelve a evolucionar

Ya no tenemos unos pocos dispositivos

Supongamos que el sistema ahora posee:

- miles de dispositivos;
- mediciones cada pocos segundos;
- varios años de histórico;
- múltiples organizaciones;
- consultas operativas en tiempo real;
- análisis históricos y comparativos;
- alertas automáticas;
- nuevos consumidores de datos.



La misma arquitectura puede seguir siendo válida, pero empiezan a aparecer tensiones nuevas entre volumen, velocidad y tipo de uso.

No es solamente “más datos”

También cambia la forma de utilizarlos

Cuando el sistema crece, no solo aumenta la cantidad de registros.

También cambian:

- la frecuencia con la que llegan;
- la diversidad de formatos;
- el tiempo durante el cual queremos conservarlos;
- la cantidad de usuarios o procesos que los consumen;
- las preguntas que queremos responder.



Grandes volúmenes implican más que tamaño: también cambian el ritmo, la variedad y el propósito del procesamiento.

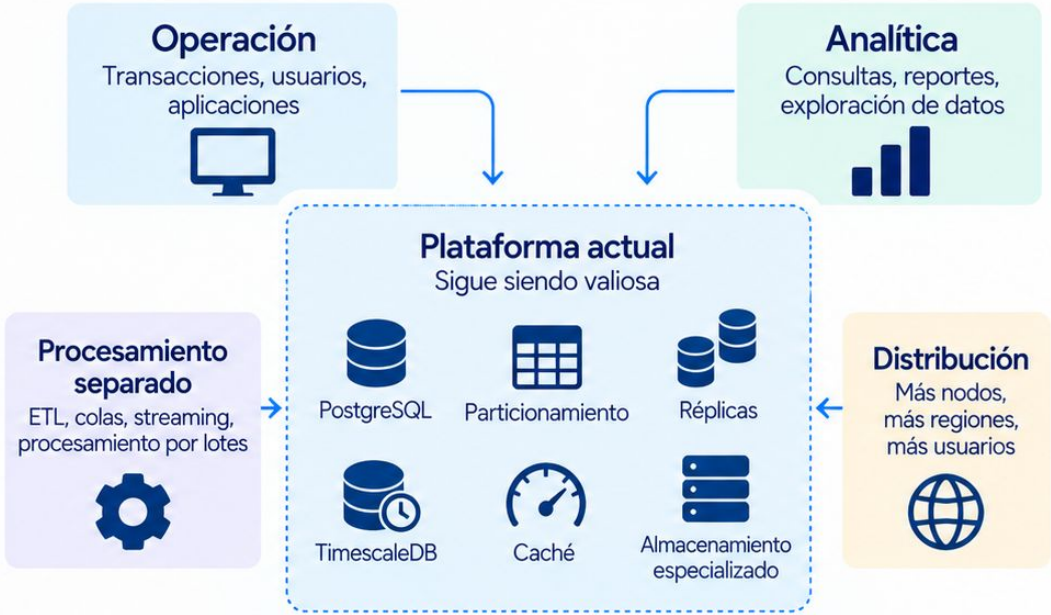
Lo anterior no deja de servir

Pero puede dejar de alcanzar por sí solo

PostgreSQL, índices, particionamiento, réplicas, TimescaleDB, caché y almacenamiento especializado siguen siendo herramientas valiosas.

La pregunta ahora es otra:

- ¿conviene resolver todo en la misma capa?;
- ¿la operación y la analítica deberían compartir la misma infraestructura?;
- ¿qué procesamiento sigue siendo local y qué procesamiento podría separarse?;
- ¿cuándo aparece la necesidad de distribuir?



La evolución hacia arquitecturas de mayor escala no reemplaza automáticamente lo anterior: lo amplía.

2

Grandes volúmenes y Big Data



Big Data

Cuando la escala empieza a condicionar las decisiones

Hablamos de Big Data cuando las características del problema hacen que:

- almacenar resulte más complejo;
- procesar demande nuevas estrategias;
- la velocidad de llegada empiece a importar mucho;
- la analítica y la operación ya no convivan cómodamente;
- la arquitectura necesite distribuir o separar responsabilidades.



Big Data aparece cuando el problema obliga a pensar distinto la arquitectura de datos.

Las 5 Vs

Una forma de describir el problema

El concepto de las 5 Vs nos ayuda a entender por qué los problemas de datos de hoy son diferentes y más desafiantes.

- **Volumen**
  ¿Cuánta información acumulamos?
- **Velocidad**
  ¿A qué ritmo llega y cuánto tarda en procesarse?
- **Variedad**
  ¿Todos los datos tienen la misma forma?
- **Veracidad**
  ¿Podemos confiar en esos datos?
- **Valor**
  ¿Para qué los almacenamos y procesamos?



Volumen

¿Cuánta información acumulamos?



Velocidad

¿A qué ritmo llega y cuánto tarda en procesarse?



Variedad

¿Todos los datos tienen la misma forma?



Veracidad

¿Podemos confiar en esos datos?



Valor

¿Para qué los almacenamos y procesamos?

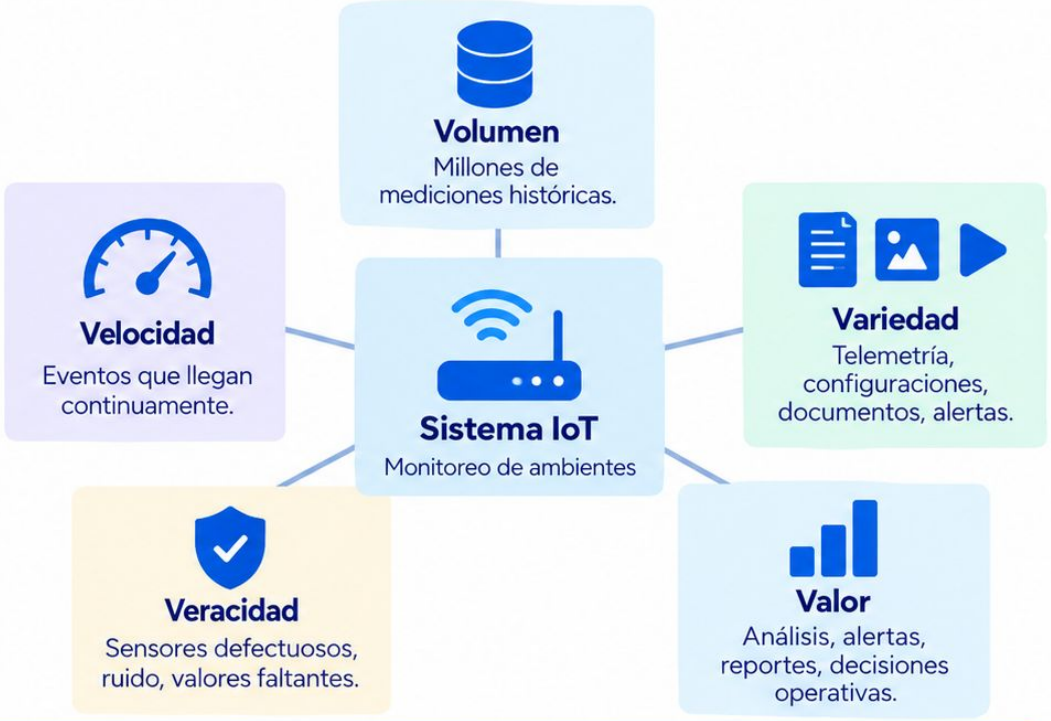


Las 5 Vs no son una definición rígida. Son una forma simple de mirar el problema desde varias dimensiones.

Las 5 Vs en IoT

Bajando el concepto a monitoreo de ambientes

- **Volumen:** millones de mediciones históricas.
- **Velocidad:** eventos que llegan continuamente.
- **Variedad:** telemetría, configuraciones, documentos, alertas.
- **Veracidad:** sensores defectuosos, ruido, valores faltantes.
- **Valor:** análisis, alertas, reportes, decisiones operativas.



El caso guía ya contiene varios elementos que permiten introducir naturalmente el problema de grandes volúmenes.

No existe un umbral universal

El problema depende del contexto

Una organización puede considerar “grande” una base de 100 millones de registros.

Otra puede trabajar cómodamente con mucho más.

La escala depende de:

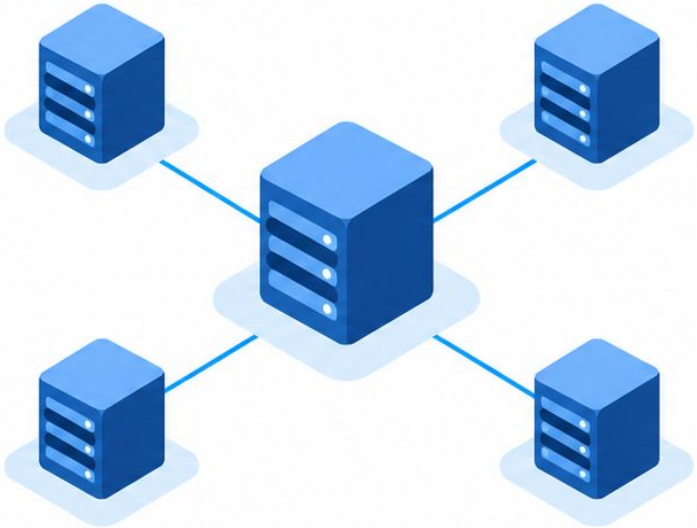
- la infraestructura disponible;
- la latencia que esperamos;
- el tipo de consultas;
- el crecimiento histórico;
- el presupuesto;
- el nivel de complejidad que estamos dispuestos a administrar.



No existe una cantidad universal de datos a partir de la cual aparece Big Data. Lo importante es cuándo la arquitectura empieza a quedar exigida.

3

Arquitecturas distribuidas



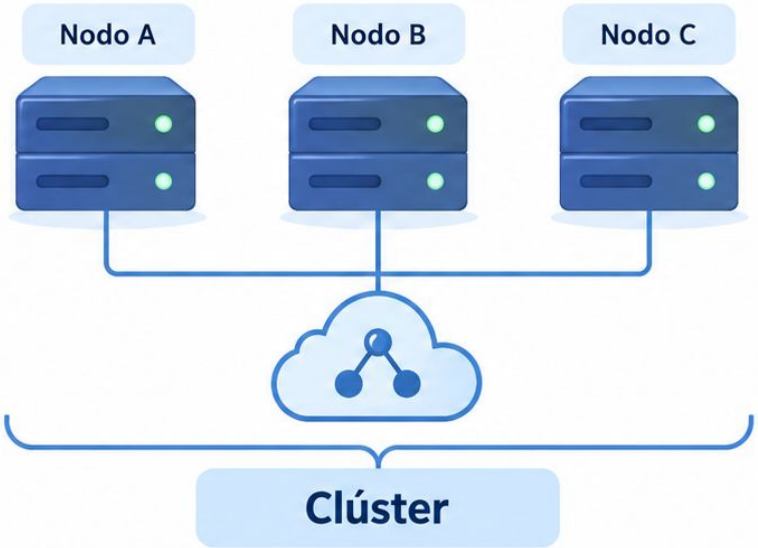
Nodo y clúster

Dos conceptos básicos

Un **nodo** es una máquina o instancia que participa de la arquitectura.

Un **clúster** es un conjunto de nodos que trabajan en conjunto.

La idea general es que el sistema ya no depende solamente de un único servidor.



Al **crecer** horizontalmente dejamos de pensar en una sola máquina y empezamos a pensar en varios nodos coordinados.

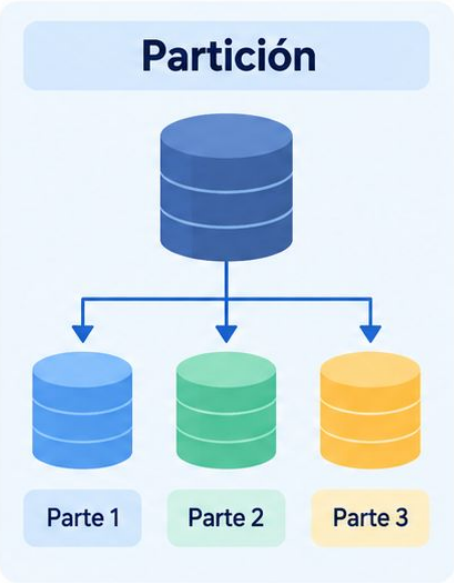
Partición y réplica

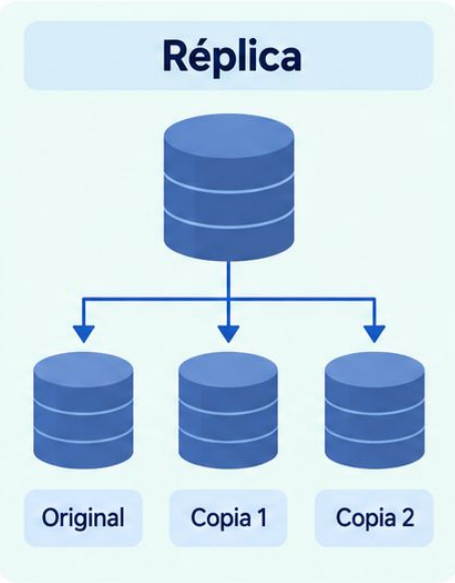
Dividir datos y copiarlos resuelven problemas diferentes

Partición
Dividir un conjunto grande de datos en partes.

Réplica
Mantener otra copia de datos existentes.

La partición ayuda a organizar o distribuir.
La réplica ayuda con disponibilidad o tolerancia a fallos.





Particionar no significa replicar, y replicar no significa distribuir el volumen entre nodos.

Dos preguntas distintas

¿Dónde viven los datos? y ¿dónde se procesan?

Una arquitectura puede necesitar:

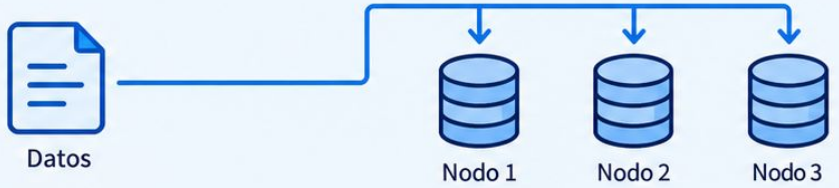
- distribuir el almacenamiento;
- distribuir el procesamiento;
- o ambas cosas al mismo tiempo.

A veces el problema es guardar mucho histórico.

Otras veces el desafío principal es procesar grandes volúmenes o flujos continuos.

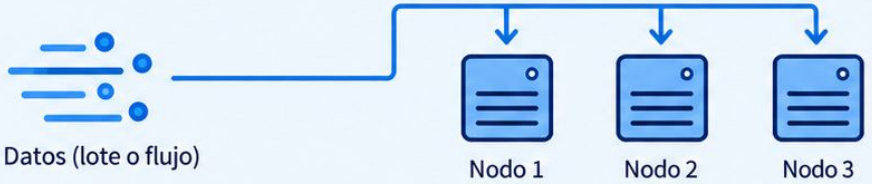
Almacenamiento distribuido

Un origen de datos repartido en varios nodos de almacenamiento.



Procesamiento distribuido

Un flujo de datos procesado en varios nodos de cómputo.



Los datos **pueden seguir** almacenados en un lugar y procesarse en otro, o bien repartirse entre varios nodos junto con su procesamiento.

La escala agrega complejidad

Crecer horizontalmente cambia la arquitectura

Cuando distribuimos aparecen nuevas preguntas:

- ¿en qué nodo está cada dato?;
- ¿cómo se coordinan los nodos?;
- ¿cómo se propagan cambios?;
- ¿qué ocurre si uno falla?;
- ¿cómo equilibramos carga?;
- ¿cómo mantenemos una visión consistente del sistema?



Distribuir ayuda a escalar, pero también introduce problemas nuevos que no existían en una arquitectura concentrada en una sola máquina.

4

Operación transaccional y analítica



Operación transaccional

El sistema funcionando en el día a día

Ejemplos en nuestro caso:

- registrar una medición;
- consultar el estado actual de un dispositivo;
- modificar una configuración;
- registrar una alerta;
- actualizar una entidad del sistema.

Suelen ser operaciones:

- puntuales;
- frecuentes;
- de baja latencia;
- asociadas al funcionamiento inmediato de la aplicación.



El procesamiento transaccional busca sostener la operación cotidiana del sistema.

Procesamiento analítico

Preguntas sobre grandes conjuntos de información

Ejemplos:

- tendencias históricas;
- máximos, mínimos y promedios;
- comparaciones entre períodos;
- análisis por organización o por zona;
- detección de patrones.

Suelen ser consultas:

- más pesadas;
- sobre mucho histórico;
- con agregaciones;
- menos orientadas a una sola fila;
- más orientadas a resumir o explicar comportamiento.



La analítica no busca solamente saber qué está pasando ahora, sino comprender qué viene ocurriendo en el tiempo.

Dos necesidades distintas

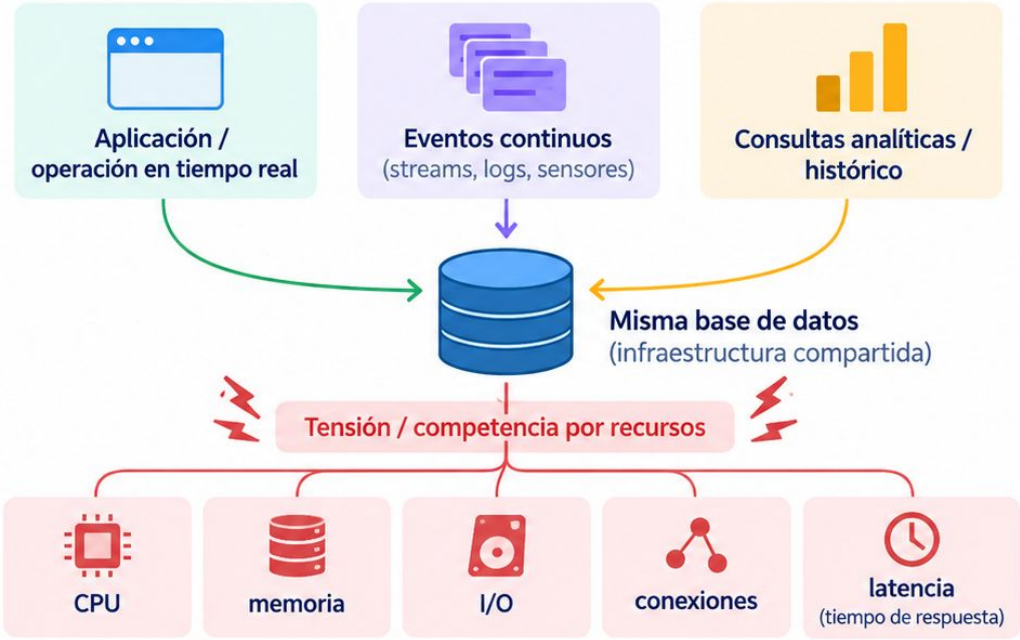
Operación y análisis no siempre conviven igual de bien

Si la misma base tiene que:

- atender la aplicación en tiempo real;
- recibir eventos constantemente;
- y además responder consultas históricas complejas,

pueden empezar a competir:

- CPU;
- memoria;
- I/O;
- conexiones;
- tiempo de respuesta.



Una de las razones por las que aparecen nuevas arquitecturas es la necesidad de separar cargas operativas y analíticas.

Una forma de pensarlo

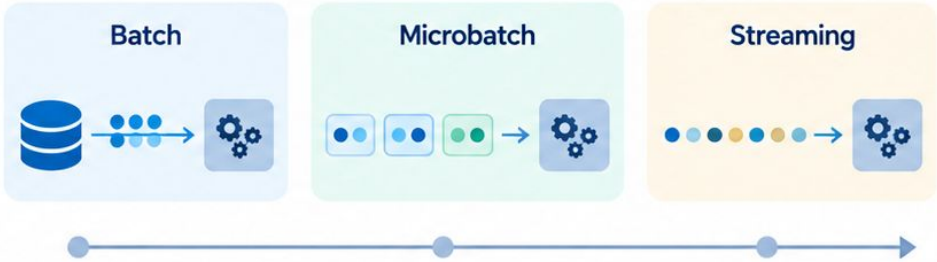
Operación por un lado, análisis por otro



No siempre significa usar herramientas completamente distintas, pero sí comenzar a diferenciar necesidades de uso.

5

Batch, microbatch y streaming



Batch

Procesar después de acumular

En procesamiento batch:

- los datos se acumulan;
- el procesamiento ocurre más tarde;
- suele ejecutarse por bloques o por períodos.



Ejemplo:

Todas las noches calcular estadísticas del día anterior.

Batch resulta natural cuando no necesitamos reaccionar de inmediato y podemos procesar por lotes.

Microbatch

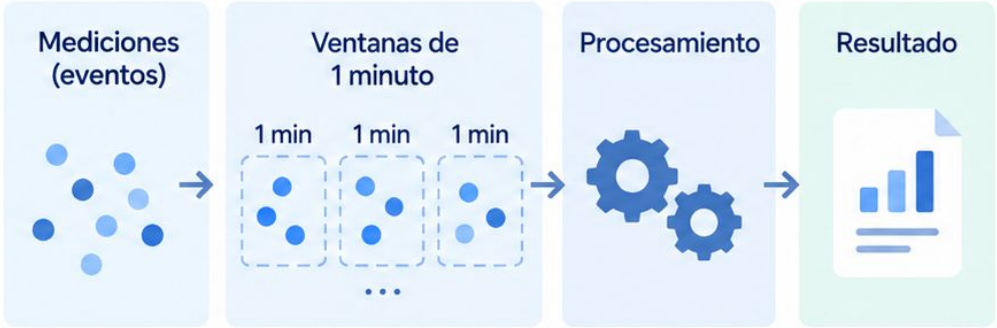
Pequeños lotes ejecutados con frecuencia

En microbatch:

- seguimos agrupando datos;
- pero en ventanas mucho más cortas;
- el retraso es menor que en batch tradicional.

Ejemplo:

Cada minuto procesar todas las mediciones recibidas durante ese minuto.



Microbatch ocupa un punto intermedio entre acumular demasiado y procesar evento por evento.

Streaming

Procesar a medida que llegan los eventos

En streaming:

- los datos forman un flujo continuo;
- el procesamiento ocurre casi en tiempo real;
- el interés suele estar en detectar rápidamente cambios o condiciones relevantes.

Ejemplo:

Si una medición supera un umbral peligroso, generar una alerta en segundos.



Streaming resulta valioso cuando la demora entre llegada y reacción importa mucho.

Tres formas de procesar

No resuelven exactamente el mismo problema

Batch
Horas o días.

Microbatch
Segundos o minutos.

Streaming
Evento continuo.

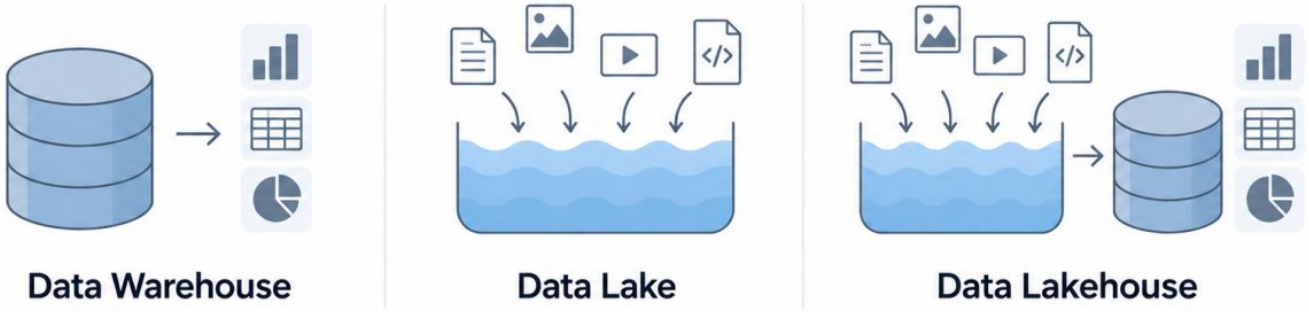
La mejor elección depende de:

- cuánto tiempo podemos esperar;
- cuánta complejidad queremos asumir;
- qué tipo de respuesta necesita el sistema.



No existe una única forma correcta de procesar datos: depende del objetivo y de la urgencia.

6



Data Warehouse, Data Lake y Data Lakehouse

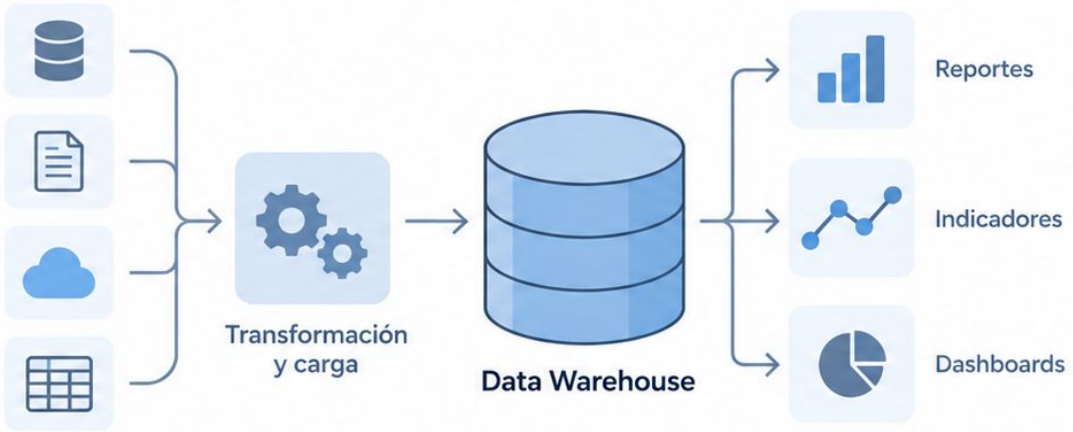
Data Warehouse

Datos organizados para análisis

Un Data Warehouse es una arquitectura pensada para:

- integrar información;
- organizarla para consulta analítica;
- facilitar reportes e indicadores;
- trabajar sobre datos estructurados y preparados.

La idea central es que la información llegue en una forma más apta para analizar.



En un Warehouse, el foco está puesto en disponer de datos organizados para responder preguntas analíticas con claridad.

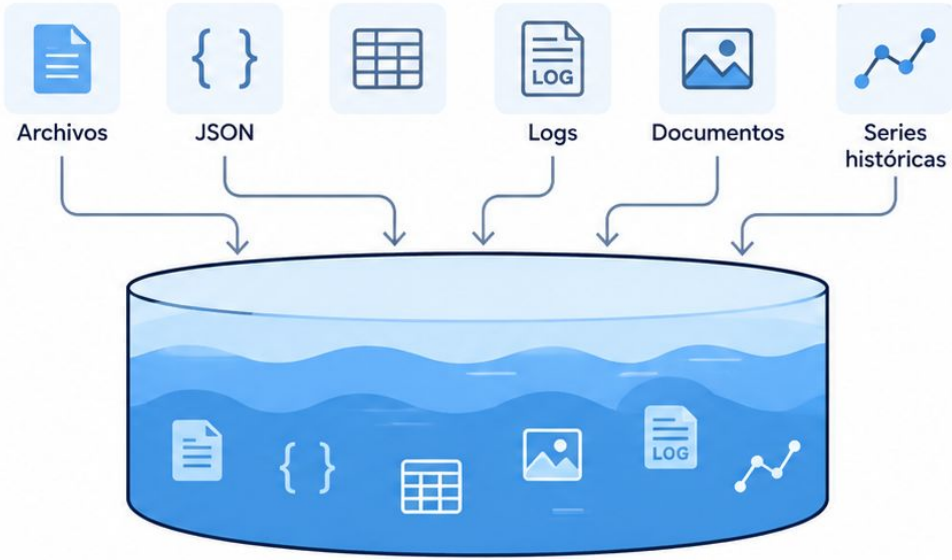
Data Lake

Conservar grandes volúmenes de datos en diversos formatos

Un Data Lake permite almacenar información de distinto tipo, por ejemplo:

- archivos;
- JSON;
- logs;
- series históricas;
- documentos;
- otros conjuntos de datos.

No todo necesita estar transformado desde el inicio. La información puede conservarse en formatos más cercanos al original.



Un Data Lake prioriza flexibilidad para conservar grandes volúmenes de datos diversos.

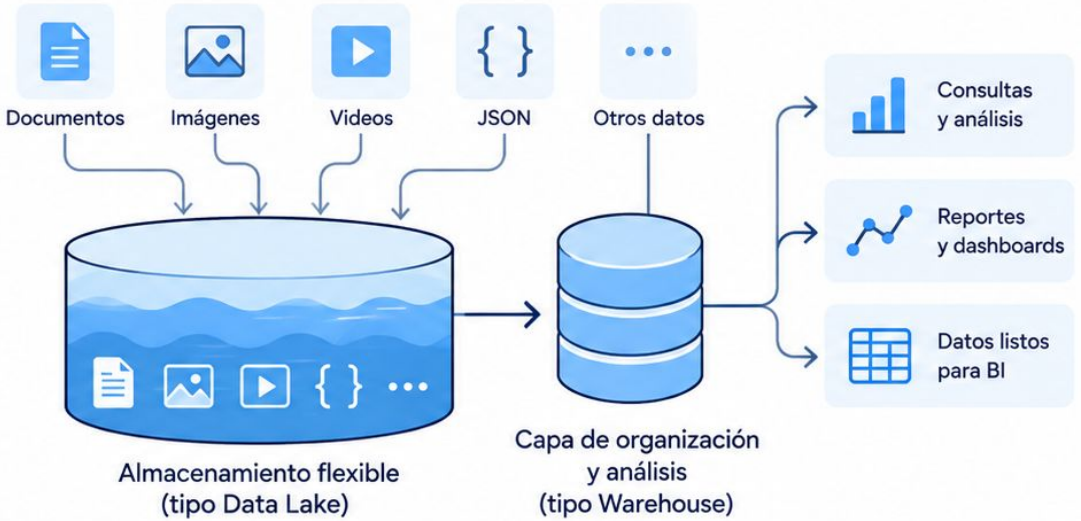
Data Lakehouse

Intentar combinar flexibilidad y capacidades analíticas

La idea de Lakehouse busca combinar:

- la flexibilidad de un Data Lake;
- con capacidades de organización y análisis más cercanas a un Warehouse.

No se trata de memorizar una tecnología puntual, sino de comprender la intención arquitectónica.



Lakehouse intenta acercar el almacenamiento amplio del Lake con una experiencia de análisis más organizada.

Comparación general

Tres enfoques, objetivos relacionados

Warehouse
Más estructurado y preparado para análisis.

Lake
Más flexible y amplio en formatos.

Lakehouse
Busca combinar ambos mundos.

Warehouse



Más estructurado y preparado para análisis.

Lake



Más flexible y amplio en formatos.

Lakehouse

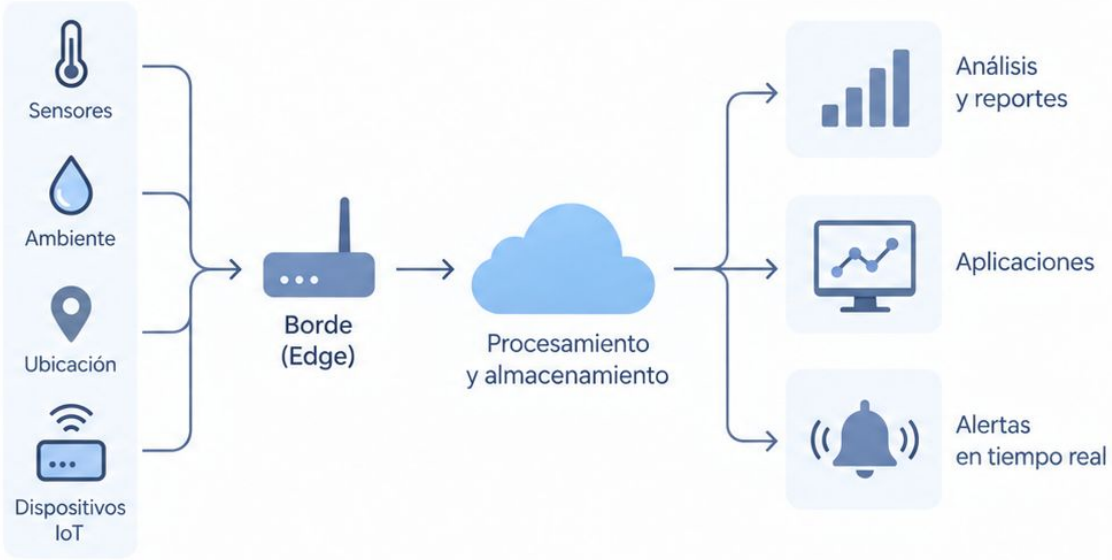


Busca combinar ambos mundos.

La elección depende del tipo de datos, del nivel de preparación requerido y del tipo de análisis que queremos realizar.

7

Evolución del caso guía



El caso sigue creciendo

Una posible evolución conceptual

Etapa 1

Dispositivos → backend → PostgreSQL.

Etapa 2

- TimescaleDB / particionamiento / caché / object storage.

Etapa 3

- usuarios, permisos, RLS, backup, réplicas.

Etapa 4

- histórico masivo, analítica, procesamiento de eventos, almacenamiento más amplio.



La arquitectura crece por capas. Lo nuevo no borra lo anterior: se apoya sobre ello.

Una vista integrada

Operación, histórico y análisis

Dispositivos
↓
Ingreso de eventos
↓
Base operativa / datos actuales

En paralelo:
eventos / histórico
↓
procesamiento
↓
almacenamiento analítico o amplio
↓
reportes / dashboards / análisis



Una arquitectura de mayor escala suele empezar a separar operación, histórico y procesamiento analítico.

No todo se mueve

Algunas cosas siguen siendo claramente transaccionales

Conviene mantener en la capa operativa, por ejemplo:

- usuarios y organizaciones;
- dispositivos;
- configuraciones;
- estado actual;
- alertas activas;
- operaciones de la aplicación.



La evolución hacia mayor escala no significa sacar todo de la base operativa.

Qué podría separarse

Histórico, analítica y procesamiento continuo

Podrían separarse o especializarse:

- históricos masivos;
- procesamiento de series extensas;
- consolidaciones por período;
- reportes pesados;
- exploración analítica;
- ciertos flujos continuos de eventos.



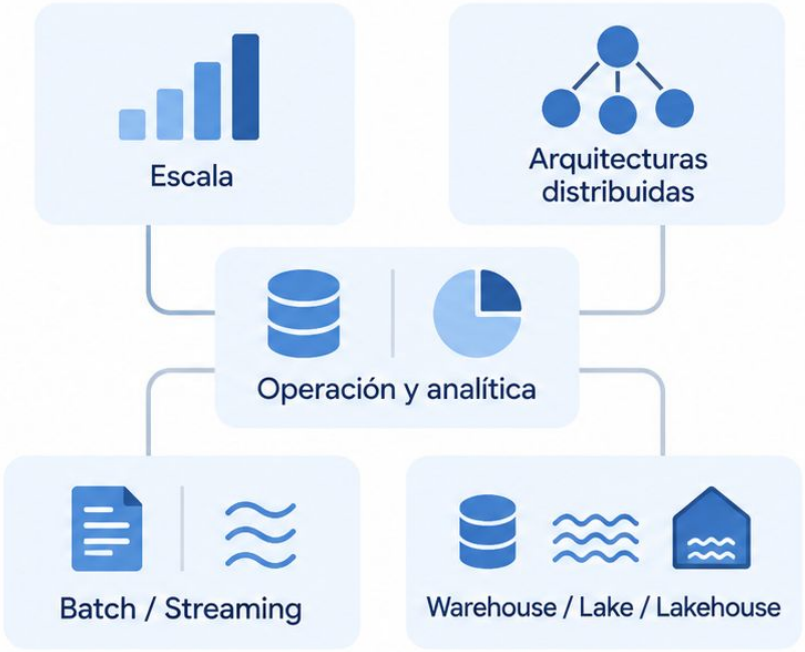
Cuando aparecen nuevas necesidades, una decisión frecuente es separar lo operativo de lo intensivo en análisis o volumen.

Para ir cerrando...

Lo importante de la clase de hoy

Hoy no buscamos dominar herramientas de Big Data.
Buscamos comprender:

- cuándo la escala cambia el problema;
- por qué aparecen arquitecturas distribuidas;
- cómo se separan operación y analítica;
- qué significan batch y streaming;
- qué rol cumplen Warehouse, Lake y Lakehouse.



La arquitectura evoluciona cuando cambian las necesidades del sistema, no por moda tecnológica.

Errores frecuentes

Problemas típicos al pensar grandes volúmenes

- creer que “muchos datos” obligan automáticamente a usar Big Data;
- pensar que distribuir siempre mejora todo;
- mezclar operación y analítica sin revisar sus tensiones;
- suponer que streaming siempre es mejor que batch;
- adoptar una arquitectura compleja sin entender primero el problema;
- confundir almacenamiento distribuido con procesamiento distribuido.



Una arquitectura más grande no siempre es una arquitectura mejor. Primero tenemos que entender qué necesidad real estamos resolviendo.

Buenas prácticas

Evolucionar con criterio

- partir del problema y no de la herramienta;
- distinguir operación de analítica;
- reconocer cuándo la latencia realmente importa;
- separar lo conceptual de lo tecnológico;
- introducir complejidad solo cuando está justificada;
- medir antes de rediseñar;
- pensar evolución gradual y no reemplazos abruptos.

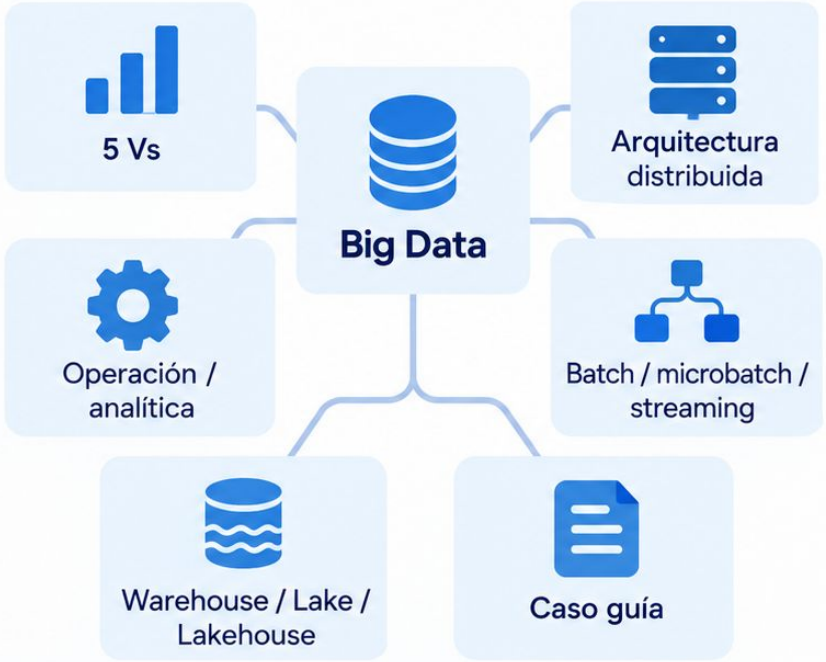


Antes de distribuir o incorporar nuevas capas, conviene entender qué está creciendo, cómo se usa y qué queremos mejorar.

Resumen de la clase

Ideas principales

- Big Data describe problemas cuya escala condiciona la arquitectura.
- Las 5 Vs ayudan a caracterizar esos problemas.
- Una arquitectura distribuida trabaja con nodos, clústeres, particiones y réplicas.
- Operación transaccional y analítica no siempre tienen las mismas necesidades.
- Batch, microbatch y streaming responden a distintos tiempos de procesamiento.
- Warehouse, Lake y Lakehouse son formas diferentes de organizar datos para análisis y evolución.
- El caso guía puede crecer separando progresivamente operación, histórico y análisis.



La idea central es reconocer cuándo una arquitectura convencional empieza a necesitar evolucionar hacia soluciones de mayor escala.

Continuidad

Cierre de la materia y proyección

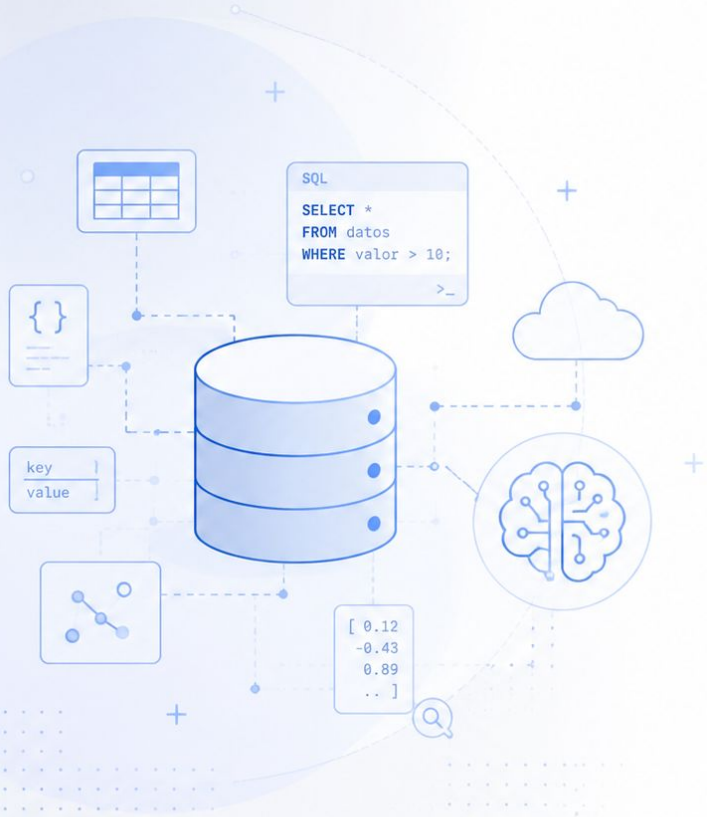
Con esta clase cerramos el recorrido principal de la materia.

A partir de acá, los conceptos que vimos permiten:

- interpretar arquitecturas más grandes;
- entender por qué aparecen nuevas tecnologías;
- analizar mejor decisiones de escalabilidad;
- continuar el estudio en materias más específicas.



No buscamos cerrar el tema de grandes volúmenes, sino dejar una base conceptual clara para seguir profundizándolo.



Muchas gracias
¿Dudas?



Enlace a la encuesta

8

Demostración / desarrollo práctico

