



Materia: Arquitectura de Datos

Carrera: Especialización en Internet de las Cosas (CEIoT)

Unidad Académica: Facultad de Ingeniería – Universidad de Buenos Aires

Profesor responsable: Esp. Lic. Martín Anibal Lacheski

Duración: 24 horas

Fundamentación

Los sistemas de Internet de las Cosas (IoT) generan y utilizan datos provenientes de dispositivos, sensores, aplicaciones, servicios externos y plataformas de procesamiento. Estos datos pueden presentar diferentes estructuras, frecuencias de actualización, volúmenes y necesidades de acceso, por lo que su correcta organización y almacenamiento constituye un componente fundamental de cualquier solución IoT.

El diseño de la arquitectura de datos requiere comprender los distintos modelos de bases de datos y seleccionar las tecnologías adecuadas según las características de la información y los requerimientos de cada sistema. Las soluciones actuales pueden combinar bases de datos relacionales, documentales, clave-valor, columnares, de grafos, series temporales, información geoespacial y almacenamiento de objetos.

La materia Arquitectura de Datos proporciona los fundamentos necesarios para modelar, almacenar, consultar, administrar y optimizar la información utilizada por aplicaciones y sistemas IoT. Se abordan los principios de modelado de datos, las bases de datos relacionales y el lenguaje SQL, los sistemas NoSQL, las tecnologías especializadas, la administración de bases de datos y los mecanismos de escalabilidad.

Asimismo, se introduce el problema de los grandes volúmenes de datos y las arquitecturas distribuidas, estableciendo las bases conceptuales necesarias para continuar su estudio en asignaturas específicas orientadas al procesamiento y explotación de Big Data.

Objetivo general

Desarrollar en los estudiantes la capacidad de diseñar, implementar y evaluar arquitecturas de datos para sistemas y aplicaciones de Internet de las Cosas, seleccionando modelos, tecnologías y mecanismos de almacenamiento de acuerdo con los requerimientos funcionales, operativos y de escalabilidad de cada solución.

Objetivos específicos

Al finalizar la materia, los estudiantes estarán en condiciones de:

- Comprender los conceptos fundamentales de bases de datos y sistemas de almacenamiento;
- Diseñar modelos conceptuales, lógicos y físicos de datos;
- Utilizar bases de datos relacionales y lenguaje SQL;
- Aplicar principios de diseño, normalización e integridad de datos;
- Utilizar índices y analizar planes de ejecución para optimizar consultas;
- Reconocer las características y aplicaciones de los principales modelos NoSQL;



- Seleccionar tecnologías especializadas según las características de los datos;
- Comprender los fundamentos de administración, concurrencia, seguridad, aislamiento de datos, recuperación y mantenimiento de bases de datos;
- Analizar estrategias de organización y aislamiento de datos en aplicaciones multi-tenant;
- Analizar alternativas de replicación, particionamiento y escalabilidad;
- Reconocer los desafíos que aparecen al gestionar grandes volúmenes y flujos continuos de datos.

Contenidos mínimos

- Conceptos generales de bases de datos.
- Modelado de datos.
- Bases de datos relacionales.
- Lenguaje de consulta estructurada SQL.
- Bases de datos no relacionales NoSQL.
- Administración y optimización de bases de datos.
- Tecnologías de almacenamiento especializadas.
- Fundamentos de escalabilidad y grandes volúmenes de datos.

Programa Sintético

1. Introducción a la arquitectura de datos. Datos, información, sistemas gestores de bases de datos y tecnologías de almacenamiento.
2. Modelado de datos. Modelado conceptual, lógico y físico. Diagramas Entidad-Relación y UML aplicado al modelado de datos.
3. Bases de datos relacionales y lenguaje SQL. Modelo relacional, integridad, restricciones, consultas y transacciones.
4. Diseño, evolución y optimización de bases de datos relacionales. Normalización, índices, vistas, JSON, planes de ejecución y evolución del esquema.
5. Bases de datos NoSQL. Bases documentales, clave-valor, columnares y de grafos. Consistencia, disponibilidad y criterios de selección.
6. Bases de datos y almacenamiento especializado para IoT. Series temporales, datos geoespaciales, caché, almacenamiento de objetos y otras tecnologías especializadas.
7. Administración, seguridad y escalabilidad de bases de datos. Usuarios, roles, permisos, arquitecturas multi-tenant, aislamiento de datos, transacciones, concurrencia, backup, recuperación, replicación, particionamiento, monitoreo y mantenimiento.
8. Arquitecturas de datos y grandes volúmenes. Escalabilidad horizontal, sistemas distribuidos, procesamiento batch y streaming e introducción a arquitecturas Big Data.

Programa Analítico

Clase 1 – Introducción a la Arquitectura de Datos

Conceptos de dato, información y conocimiento. Arquitectura de datos y su relación con la arquitectura de software y los sistemas IoT. Fuentes, mecanismos de ingreso, almacenamiento, procesamiento y consumo de datos. Datos estructurados, semiestructurados y no estructurados. Sistemas gestores de bases de datos. Componentes y funciones de un SGBD. Clasificación de bases de datos y sistemas de almacenamiento. Bases relacionales, NoSQL y tecnologías especializadas. Persistencia y ciclo de vida de los



datos generados por dispositivos y aplicaciones.

Clase 2 – Modelado de Datos

Modelado conceptual, lógico y físico. Modelo Entidad-Relación. Entidades, atributos y relaciones. Identificadores, cardinalidades y restricciones. Claves naturales y sustitutas. UML aplicado al modelado de datos. Transformación de requerimientos funcionales en estructuras de datos. Modelado de dispositivos, sensores, mediciones, eventos, usuarios, organizaciones, ubicaciones y configuraciones. Historiales y evolución de estados. Errores frecuentes de modelado.

Clase 3 – Bases de Datos Relacionales y Lenguaje SQL

Fundamentos del modelo relacional. Tablas, filas, columnas y dominios. Claves primarias y foráneas. Restricciones e integridad referencial. Lenguajes DDL, DML y DQL. Creación, inserción, modificación y eliminación de datos. Consultas mediante filtros, ordenamiento, agregaciones y agrupamientos. JOIN, subconsultas y expresiones comunes de tabla. Introducción a funciones de ventana. Transacciones básicas. Consultas parametrizadas.

Clase 4 – Diseño Relacional, Optimización y Evolución del Esquema

Principios de diseño relacional. Dependencias, redundancia y normalización. Primera, Segunda y Tercera Forma Normal. Desnormalización justificada. Índices simples y compuestos. Selectividad y costo de mantenimiento. Planes de ejecución. Uso de EXPLAIN y EXPLAIN ANALYZE. Vistas y vistas materializadas. Gestión de información semiestructurada mediante JSON y JSONB. Criterios para seleccionar columnas, tablas relacionadas o documentos JSON. Migraciones, versionado y evolución del esquema.

Clase 5 – Bases de Datos NoSQL

Motivación y fundamentos del paradigma NoSQL. Flexibilidad de esquema, distribución, disponibilidad, consistencia y escalabilidad. Introducción conceptual al teorema CAP. Bases de datos documentales. Modelado mediante documentos y colecciones. Casos de uso para configuración, metadatos y estructuras variables. Bases de datos clave-valor. Acceso mediante claves, almacenamiento temporal, estados y caché. Bases de datos columnares distribuidas. Particionamiento, distribución y acceso orientado a patrones de consulta. Bases de datos de grafos. Nodos, relaciones y propiedades. Modelado de topologías, dependencias, redes de dispositivos y relaciones complejas. Criterios de selección entre bases relacionales y NoSQL. Persistencia políglota y prevención del sobrediseño.

Clase 6 – Bases de Datos y Almacenamiento Especializado para IoT

Características de los datos generados por sistemas IoT. Mediciones, eventos, timestamps, ubicación y frecuencia de adquisición. Bases de datos de series temporales. Organización de mediciones en el tiempo. Timestamp, dispositivo, variable, valor y etiquetas. Retención, agregaciones temporales y downsampling. Introducción a extensiones y motores especializados para series temporales. Datos geoespaciales. Coordenadas, geometrías y relaciones espaciales. Consultas por ubicación, distancia, proximidad y pertenencia a regiones. Introducción a extensiones geoespaciales. Caché y almacenamiento temporal. Casos de uso y estrategias de expiración. Almacenamiento de archivos y objetos. Separación entre contenido físico y metadatos. Servicios compatibles con almacenamiento de objetos. Introducción a otras tecnologías especializadas, como bases vectoriales, motores



de búsqueda y extensiones específicas de los sistemas gestores modernos. Criterios para seleccionar y combinar tecnologías de almacenamiento.

Clase 7 – Administración, Seguridad y Escalabilidad de Bases de Datos

Usuarios, autenticación, roles y permisos. Principio de mínimo privilegio. Usuarios administrativos y usuarios de aplicación. Aplicaciones multi-tenant. Concepto de tenant y aislamiento de datos. Estrategias mediante bases de datos separadas, esquemas separados o tablas compartidas. Uso de identificadores de tenant. Introducción a Row Level Security para la aplicación de políticas de aislamiento. Transacciones y propiedades ACID. Concurrencia, aislamiento, bloqueos y conflictos entre operaciones simultáneas. Copias de seguridad y restauración. Recuperabilidad y tolerancia a fallos. Registros de transacciones. Monitoreo de bases de datos. Conexiones, utilización de recursos, crecimiento del almacenamiento y consultas lentas. Operaciones de mantenimiento. Replicación de datos. Réplicas y alta disponibilidad. Particionamiento de tablas y datos. Criterios de particionamiento. Escalabilidad vertical y horizontal.

Clase 8 – Arquitecturas de Datos y Grandes Volúmenes

Limitaciones de los sistemas tradicionales ante el crecimiento del volumen, velocidad y variedad de los datos. Introducción al paradigma Big Data y sus principales desafíos. Volumen, velocidad, variedad, veracidad y valor. Distribución de datos y procesamiento. Nodos, clústeres, particiones y replicación. Diferencias entre sistemas transaccionales y analíticos. Introducción conceptual al procesamiento batch, microbatch y streaming. Eventos y flujos continuos de información provenientes de dispositivos IoT. Panorama de arquitecturas Data Warehouse, Data Lake y Data Lakehouse. Introducción a formatos y tecnologías utilizadas en arquitecturas de grandes volúmenes de datos. Criterios para determinar cuándo una solución requiere evolucionar desde una arquitectura de base de datos convencional hacia una arquitectura distribuida de procesamiento de datos. Integración de los conceptos desarrollados durante la materia y análisis de alternativas de arquitectura para diferentes escenarios IoT.

Relación entre los contenidos de la asignatura y los objetivos de la carrera

La Especialización en Internet de las Cosas busca formar profesionales capaces de diseñar, desarrollar, integrar y gestionar soluciones que articulan dispositivos, sensores, sistemas de comunicación, plataformas de procesamiento y aplicaciones de software.

En este contexto, la asignatura Arquitectura de Datos aporta los conocimientos necesarios para modelar, almacenar, consultar, administrar y proteger la información generada y utilizada por los sistemas IoT. Sus contenidos abarcan modelado de datos, bases de datos relacionales y lenguaje SQL, sistemas NoSQL, tecnologías especializadas para series temporales y datos geoespaciales, administración, optimización, concurrencia, seguridad, aislamiento de datos en aplicaciones multi-tenant y escalabilidad.

La materia permite además comprender cómo seleccionar y combinar diferentes tecnologías de almacenamiento según las características de los datos, la frecuencia de adquisición, los patrones de acceso y los requerimientos operativos de cada solución. De este modo, complementa las demás asignaturas de la especialización y proporciona las bases necesarias para abordar posteriormente arquitecturas orientadas al procesamiento distribuido y a la gestión de grandes volúmenes de datos.



Actividades prácticas a desarrollar, modalidad de supervisión y evaluación

Las clases incluirán actividades prácticas orientadas a la aplicación de los conceptos desarrollados durante cada encuentro. Estas actividades contemplarán ejercicios de modelado de datos, creación y consulta de bases de datos relacionales, utilización de lenguaje SQL, análisis y optimización de consultas, evaluación de modelos NoSQL y experimentación con tecnologías de almacenamiento aplicables a sistemas IoT.

También se desarrollarán actividades relacionadas con series temporales, información geoespacial, administración de bases de datos, gestión de usuarios y permisos, aislamiento de datos en aplicaciones multi-tenant, Row Level Security, copias de seguridad, particionamiento, concurrencia y análisis de alternativas de escalabilidad.

Cuando resulte adecuado, los servicios utilizados durante las prácticas podrán desplegarse mediante contenedores para facilitar la reproducción y configuración de los entornos de trabajo.

La supervisión se realizará durante las clases mediante demostraciones, actividades guiadas, resolución de consultas, análisis de alternativas tecnológicas y revisión de los resultados obtenidos.

La evaluación podrá realizarse mediante exámenes teóricos, exámenes prácticos, ejercicios o trabajos breves correspondientes a los distintos temas de la materia. Las instancias de evaluación contemplarán aspectos de modelado, consultas SQL, diseño relacional, optimización, selección de tecnologías de almacenamiento, administración y análisis de arquitecturas de datos.